



AI/ML Tabanlı FinTech Uygulaması Geliştirme

AI Kredi Skorlama Sistemi Ara Raporu

Problem Tanımı | Veri Seti | Yöntem / Model

Hazırlayan: Esra Karadağ

Öğrenci Numarası: 1306220178

Ders: Finansta Bilişim Teknolojileri

Rapor Türü: Ara Rapor

Tarih: Mayıs 2026

Proje Konusu	AI Kredi Skorlama Sistemi
Alan	FinTech / Kredi ve Risk Analitiği
Ara Rapor Kapsamı	1. Problem Tanımı, 2. Veri Seti, 3. Yöntem / Model
Seçilen Problem	Müşterinin kredi geri ödeme riskini tahmin etme
Beklenen Çıktı	Kredi skoru + APPROVE / REVIEW / DECLINE karar önerisi

Ara Rapor Notu

Bu rapor, proje yönergesindeki ara rapor kapsamına uygun olarak yalnızca ilk üç ana bölümü içermektedir. Uygulama, sistem mimarisi ve nihai sonuçlar final raporda detaylandırılacaktır.

İçindekiler

Ara Rapor Özeti

1. Problem Tanımı

1.1 Seçilen Problemin Açıklaması

1.2 Problemin Önemi

1.3 Çalışmanın Amacı

2. Veri Seti

2.1 Veri Kaynağı

2.2 Veri İçeriği ve Feature Açıklamaları

2.3 Veri Ön İşleme Adımları

2.4 Örnek Veri Seti

3. Yöntem / Model

3.1 Kullanılan Modeller

3.2 Model Seçimi Gerekçesi

3.3 Beklenen Model Çıktıları

Ara Rapor Genel Değerlendirmesi

Ara Rapor Özeti

Bu ara raporda, AI/ML tabanlı FinTech uygulaması geliştirme projesi kapsamında seçilen AI Kredi Skorum Sistemi ele alınmıştır. Projenin temel amacı, kredi başvurusu yapan bir müşterinin geri ödeme riskini tahmin eden, bu riski kredi skoruna dönüştüren ve kullanıcıya APPROVE / REVIEW / DECLINE şeklinde karar önerisi sunabilen bir sistem geliştirmektir.

Bu aşamada öncelikle kredi skorum problemi tanımlanmış, problemin finans sektörü açısından önemi açıklanmış ve çalışmanın amacı belirlenmiştir. Daha sonra kullanılan veri seti incelenmiş, veri setindeki değişkenler açıklanmış ve veri ön işleme süreci değerlendirilmiştir. Son bölümde ise bu problem için kullanılabilecek makine öğrenmesi modelleri ele alınmış, model seçimi yapılırken hangi kriterlerin dikkate alınacağı yorumlanmıştır.

Bu projede kredi riski problemi yalnızca doğru tahmin yapma problemi olarak görülmemiştir. Kredi skorum alanında farklı hata türlerinin farklı finansal maliyetleri olduğu için model performansı değerlendirilirken yalnızca accuracy metriğine bakmanın yeterli olmayacağı sonucuna varılmıştır. Özellikle kötü kredi riskine sahip müşterileri yakalayabilmek için bad credit recall metriğinin önemli olduğu değerlendirilmiştir.

Seçilen Proje Konusu	AI Kredi Skorum Sistemi
Problem Türü	İkili sınıflandırma ve kredi risk skorum
Kullanılan Veri Seti	South German Credit
Ara Rapor Kapsamı	Problem Tanımı, Veri Seti, Yöntem / Model

1. Problem Tanımı

1.1 Seçilen Problemin Açıklaması

Bu projede finans teknolojileri alanında AI kredi skortlama sistemi problemi seçilmiştir. Kredi skortlama, bir müşterinin kredi başvurusu sırasında verdiği bilgilerden yararlanarak müşterinin krediyi geri ödeme riskini tahmin etmeyi amaçlayan bir karar destek problemidir.

Bir müşteri kredi başvurusu yaptığında finansal kurum açısından temel soru şudur: “Bu müşteri aldığı krediyi düzenli ve güvenilir şekilde geri ödeyebilir mi?” Bu soruya doğru cevap vermek finansal kurumlar için önemlidir. Çünkü verilen kredi geri ödenmezse kurum doğrudan finansal zarara uğrayabilir. Diğer taraftan, aslında güvenilir olan bir müşteri yanlışlıkla reddedilirse kurum hem müşteri kaybı hem de gelir fırsatı kaybı yaşayabilir.


Bu nedenle kredi skortlama problemi hem teknik hem de iş kararları açısından dikkatli ele alınması gereken bir problemidir. Bu projede problem, makine öğrenmesi açısından bir ikili sınıflandırma problemi olarak değerlendirilmiştir. Modelin görevi, müşteriye ait kredi başvuru bilgilerini kullanarak müşterinin kredi riskini tahmin etmektir.

Projede hedeflenen sistem yalnızca “iyi kredi” veya “kötü kredi” tahmini yapmakla sınırlı değildir. Model çıktısının kullanıcı tarafından daha anlaşılır hale getirilmesi için kredi skoru, risk olasılığı, risk bandı ve karar önerisi de üretilmesi hedeflenmiştir.

Tablo 1. Projede Hedeflenen Karar Destek Çıktıları

Çıktı	Açıklama
Kredi skoru	Müşterinin model tabanlı kredi skoru
Bad Credit Probability	Müşterinin kötü kredi riski olasılığı
Good Credit Probability	Müşterinin iyi kredi olasılığı
Risk Band	Low Risk, Medium Risk veya High Risk seviyesi
Decision	APPROVE, REVIEW veya DECLINE karar önerisi

Bu çıktı yapısı sayesinde proje sadece bir sınıflandırma modeli olmaktan çıkıp, FinTech alanında kullanılabilecek bir kredi karar destek sistemi haline getirilmeyi amaçlamaktadır. Bu noktada benim için önemli olan şey, model sonucunun yalnızca teknik bir tahmin olarak kalmaması, kullanıcı tarafından anlaşılabilir bir kredi skoru ve karar önerisine dönüştürülmesidir.



Şekil 1. Kredi Skortlama Sisteminin Genel Akışı

Bu akış, müşteri başvuru bilgilerinin önce modelin kullanabileceği forma getirildiğini, ardından makine öğrenmesi modeli ile risk olasılığı üretildiğini göstermektedir. Risk olasılığı daha sonra kredi skoruna ve karar önerisine dönüştürülmektedir.

1.2 Problemin Önemi

Kredi riski, bankalar, dijital bankacılık platformları ve FinTech şirketleri için doğrudan kârlılığı etkileyen temel problemlerden biridir. Finansal kurumlar kredi başvurularını değerlendirirken hızlı, tutarlı ve veri temelli kararlar vermek zorundadır. Özellikle dijitalleşen finans dünyasında kullanıcılar hızlı sonuç beklerken, kurumların da riskli başvuruları doğru şekilde ayırt etmesi gerekmektedir.


Geleneksel kredi değerlendirme süreçlerinde kararlar çoğu zaman sabit kurallara, geçmiş ödeme bilgilerine veya manuel değerlendirmelere dayanabilir. Bu yöntemler bazı durumlarda işe yarasa da, müşteri verisindeki karmaşık ilişkileri her zaman yeterince yakalayamayabilir. AI/ML tabanlı sistemler ise geçmiş verilerden öğrenerek müşterinin risk profilini daha sistematik biçimde değerlendirebilir.

Bu projede beni en çok ilgilendiren noktalardan biri, kredi skortama probleminde model başarısının yalnızca yüksek doğruluk oranı ile ölçülemeyecek olmasıdır. Örneğin bir model genel olarak yüksek accuracy değerine sahip olabilir; fakat kötü kredi riskine sahip müşterileri yeterince yakalayamıyorsa bu model kredi riski açısından güvenilir olmayabilir.

Tablo 2. Kredi Skortama Problemünde Hata Türlerinin Yorumu

Hata Türü	Olası Sonuç
İyi müşteriyi riskli tahmin etmek	Müşteri kaybı ve fırsat kaybı
Riskli müşteriyi iyi tahmin etmek	Finansal zarar ve kredi geri ödenmeme riski

Bu iki hata türünü karşılaştırdığımda, riskli müşteriyi iyi müşteri olarak sınıflandırmanın daha kritik bir hata olduğunu gördüm. Çünkü bu durumda finansal kurum doğrudan kredi geri ödenmeme riskiyle karşılaşabilir. Bu nedenle kredi skortama probleminde yalnızca genel doğruluk oranına bakmak yeterli değildir. Modelin özellikle riskli müşterileri yakalama başarısı da değerlendirilmelidir.



Şekil 2. Kredi Skortama Problemünde Hata Türlerinin Finansal Anlamı

Çizdiğim bu diyagramdan çıkardığım sonuç şudur: kredi riski probleminde iki hata türü aynı finansal etkiye sahip değildir. Riskli müşteriyi iyi müşteri olarak tahmin etmek, finansal kurum açısından kredi geri ödenmeme riskine yol açabileceği için daha kritik bir hata olarak değerlendirilmiştir.

Analitik Yorum

Kredi skortlama gibi finansal risk problemlerinde modelin başarısı yalnızca matematiksel bir başarı değildir. Modelin hangi hata türlerini yaptığı ve bu hataların finansal etkisi birlikte değerlendirilmelidir. Bu nedenle bu projede accuracy metriğinin yanında özellikle bad credit recall metriği de önemli görülmüştür.

1.3 Çalışmanın Amacı

Bu çalışmanın amacı, kredi başvurusu yapan bir müşterinin geri ödeme riskini tahmin eden ve kullanıcıya anlaşılır çıktılar sunan AI/ML tabanlı bir FinTech sistemi geliştirmektir.

Çalışma kapsamında önce kredi skortlama problemine uygun bir veri seti seçilmiş, ardından veri setindeki değişkenler incelenmiş ve modelleme için uygun hale getirilmiştir. Sonraki aşamada farklı makine öğrenmesi modellerinin karşılaştırılması ve kredi riski problemi için en uygun yaklaşımın belirlenmesi hedeflenmiştir.

Bu projede yalnızca teknik olarak çalışan bir model oluşturmak değil, model sonucunu kredi skoru ve karar önerisi şeklinde yorumlanabilir hale getirmek de amaçlanmıştır. Bu nedenle çalışma, hem makine öğrenmesi hem de finansal karar destek sistemi bakış açısıyla ele alınmıştır.

Tablo 3. Çalışmanın Temel Amaçları

Amaç	Açıklama
Kredi riskini tahmin etmek	Müşterinin kredi geri ödeme riskini modellemek
Veri setini analiz etmek	Müşteri başvuru bilgilerini ve hedef değişkeni incelemek
Veri ön işleme yapmak	Veriyi modelin kullanabileceği forma getirmek
Model geliştirmek	Uygun makine öğrenmesi modellerini denemek
Model karşılaştırması yapmak	Accuracy, recall, precision ve F1-score gibi metriklerle değerlendirme yapmak
Kredi skoru üretmek	Model olasılığını kullanıcı dostu skor formatına dönüştürmek
Karar önerisi üretmek	APPROVE / REVIEW / DECLINE çıktısı vermek

Bu bölümde kredi skortlama problemini sadece teknik bir sınıflandırma problemi olarak değil, aynı zamanda finansal karar kalitesini etkileyen bir risk değerlendirme problemi olarak ele aldım. Bu nedenle projenin amacı yalnızca doğru tahmin yapan bir model geliştirmek değil, aynı zamanda bu tahmini kredi skoru ve karar önerisi şeklinde anlaşılır hale getirmektir.

2. Veri Seti

2.1 Veri Kaynağı

Bu projede kredi skorlama problemi için South German Credit veri seti kullanılmıştır. Bu veri seti, kredi başvurusu yapan müşterilere ait finansal ve demografik bilgileri içermektedir. Veri seti, kredi riskini tahmin etmek amacıyla kullanılan German Credit veri seti ailesiyle ilişkilidir.

Veri setinde her satır bir müşteriyi temsil etmektedir. Her müşteri için kredi süresi, kredi tutarı, kredi geçmişi, tasarruf durumu, çalışma süresi, yaş, konut durumu, iş tipi gibi değişkenler bulunmaktadır. Bu değişkenler kullanılarak müşterinin kredi geri ödeme riski tahmin edilmeye çalışılmıştır.

Bu veri setini seçmemin nedeni, kredi skorlama problemi için gerekli olan hem finansal hem de müşteri profiline ilişkin bilgileri içermesidir. Yani model yalnızca kredi tutarı gibi tek bir değişkene bakmak yerine, müşterinin geçmiş kredi davranışı, ödeme yükü, tasarruf durumu ve çalışma süresi gibi farklı değişkenleri birlikte değerlendirebilmektedir.

Tablo 4. Hedef Değişken Yapısı

Hedef Değişken	Anlamı
0	Kötü kredi riski
1	İyi kredi riski

Bu yapı nedeniyle problem ikili sınıflandırma problemi olarak modellenmiştir. Model, müşteri bilgilerini kullanarak müşterinin iyi kredi veya kötü kredi sınıfına ait olma olasılığını tahmin etmeyi amaçlamaktadır.

2.2 Veri İçeriği ve Feature Açıklamaları

Veri setindeki değişkenler müşterinin kredi başvurusuna, finansal durumuna ve bazı demografik özelliklerine ilişkin bilgiler içermektedir. Model bu değişkenlerden yararlanarak müşterinin kredi riskini tahmin etmektedir.

Bu bölümde veri setindeki temel feature'lar incelenmiştir. Feature'ları yalnızca teknik değişkenler olarak değil, kredi riski açısından ne anlama geldikleriyle birlikte değerlendirdim. Çünkü kredi skorlama probleminde modelin hangi bilgilerden yararlandığını anlamak, modelin karar mantığını yorumlamak açısından önemlidir.

Tablo 5. Veri Setindeki Temel Feature Açıklamaları

Feature	Açıklama	Kredi Riski Açısından Yorumu
status	Müşterinin mevcut hesap durumu	Hesap durumu zayıfsa finansal risk artabilir
duration	Kredinin süresi	Uzun vadeli kredilerde belirsizlik daha fazla olabilir
credit_history	Müşterinin geçmiş kredi davranışı	Geçmiş ödeme davranışı risk tahmininde önemli olabilir
purpose	Kredinin kullanım amacı	Kredi amacı risk profilini etkileyebilir
amount	Talep edilen kredi tutarı	Yüksek kredi tutarı geri ödeme yükünü artırabilir
savings	Tasarruf durumu	Düşük tasarruf seviyesi finansal tamponun zayıf olduğunu gösterebilir
employment_duration	Çalışma süresi	Uzun çalışma süresi gelir istikrarı açısından olumlu olabilir
installment_rate	Taksit yükü	Taksit yükü arttıkça ödeme zorluğu oluşabilir
personal_status_sex	Kişisel durum ve cinsiyet bilgisi	Veri setindeki demografik değişkenlerden biridir
other_debtors	Ortak borçlu veya kefil durumu	Kefil veya ortak borçlu varlığı riski etkileyebilir
present_residence	Mevcut adreste yaşama süresi	Yerleşim istikrarı açısından yorumlanabilir
property	Mülk durumu	Varlık sahibi olmak finansal güç göstergesi olabilir
age	Müşteri yaşı	Finansal istikrar ve gelir düzeniyle ilişkili olabilir
other_installment_plans	Başka taksit planları	Ek ödeme yükümlülükleri riski artırabilir
housing	Konut durumu	Kira veya ev sahibi olma durumu finansal yükü etkileyebilir
number_credits	Mevcut kredi sayısı	Fazla kredi sayısı borç yükünü artırabilir
job	İş tipi	Gelir düzenliliği açısından önemli olabilir
people_liable	Bakmakla yükümlü olunan kişi sayısı	Müşterinin finansal sorumluluğunu etkileyebilir
telephone	Telefon kaydı	Veri setindeki başvuru değişkenlerinden biridir
foreign_worker	Yabancı çalışan durumu	Veri setindeki başvuru değişkenlerinden biridir


Bu değişkenleri incelediğimde kredi riskinin tek bir değişkene bağlı olmadığını gördüm. Örneğin yalnızca kredi tutarına bakarak karar vermek yeterli değildir. Kredi tutarı düşük olsa bile müşterinin tasarrufu zayıf, taksit yükü yüksek veya kredi geçmişi problemlili olabilir. Benzer şekilde yüksek kredi tutarı her zaman kötü kredi anlamına gelmeyebilir; eğer müşterinin çalışma süresi, tasarruf durumu ve kredi geçmişi olumluysa risk daha dengeli olabilir.

Bu nedenle modelin birden fazla değişkeni birlikte değerlendirmesi gerekmektedir. Bu durum, kredi skorlama problemini makine öğrenmesi için uygun hale getirmektedir. Bu aşamada veri setinin proje konusu için uygun olduğu sonucuna vardım; çünkü veri seti müşterinin finansal durumunu, kredi geçmişini ve bazı profil bilgilerini birlikte değerlendirmeye imkân vermektedir.

2.3 Veri Ön İşleme Adımları

Makine öğrenmesi modelleri ham veriyi doğrudan her zaman sağlıklı şekilde kullanamaz. Bu nedenle veri ön işleme aşaması model performansı açısından önemli bir adımdır. Bu projede veri seti modelleme için hazırlanırken hedef değişken belirlenmiş, girdi değişkenleri ayrılmış ve modelin kullanabileceği veri formatı oluşturulmuştur.

Bu aşamada veri ön işleme sürecini yalnızca teknik bir hazırlık olarak değil, modelin güvenilir çalışması için gerekli bir adım olarak değerlendirdim. Çünkü kredi skorlama sisteminde eğitim sırasında kullanılan feature yapısı ile tahmin aşamasında kullanılan feature yapısının aynı olması gerekir. Aksi halde model gerçek veya örnek müşteri verisi geldiğinde doğru şekilde tahmin üretemez.



Şekil 3. Veri Ön İşleme Sürecinin Genel Akışı

Bu akış, ham veri setinin doğrudan modele verilmediğini göstermektedir. Önce hedef değişken belirlenmiş, ardından girdi değişkenleri ve hedef değişken ayrılmıştır. Daha sonra veri eğitim ve test kümelerine bölünerek model eğitimi için tutarlı bir yapı oluşturulmuştur.

Tablo 6. Veri Ön İşleme Adımları

Adım	Açıklama	Neden Gerekli?
Hedef değişkenin belirlenmesi	credit_risk hedef değişken olarak ele alınmıştır	Modelin neyi tahmin edeceğini belirlemek için
Feature-target ayrımı	Girdi değişkenleri X, hedef değişken y olarak ayrılmıştır	Eğitim sürecini düzenlemek için
Veri format kontrolü	Değişkenlerin modelin beklediği formatta olması sağlanmıştır	Tahmin sırasında hata oluşmaması için
Kategorik değişkenlerin ele alınması	Sayısal kodlu kategorik değişkenler modelde kullanılacak şekilde düzenlenmiştir	Modelin kategorik bilgileri işleyebilmesi için
Eğitim-test ayrımı	Veri eğitim ve test kümelerine ayrılmıştır	Modelin genelleme başarısını ölçmek için
Sınıf dengesizliği değerlendirmesi	Kötü kredi sınıfının yakalanması ayrıca dikkate alınmıştır	Kredi riski açısından kritik sınıfı kaçırmamak için
Pipeline yaklaşımı	Ön işleme ve model adımları aynı tahmin akışında düşünülmüştür	Eğitim ve tahmin süreçlerinin tutarlı olması için

Bu ön işleme adımları sayesinde veri seti modelin kullanabileceği tutarlı bir yapıya getirilmiştir. Burada özellikle feature-target ayrımı ve eğitim-test ayrımı önemlidir. Çünkü modelin yalnızca eğitim verisini ezberlemesi değil, daha önce görmediği test verileri üzerinde de anlamlı tahminler üretebilmesi beklenmektedir.

Bu aşamada vardığım sonuç şudur: veri ön işleme, model kurmadan önce yapılan basit bir hazırlık değildir. Aksine, modelin güvenilir çalışması için temel aşamalardan biridir. Kredi skorlama gibi karar destek problemlerinde veri formatındaki küçük bir hata bile yanlış risk değerlendirmesine neden olabileceği için bu sürecin dikkatli yapılması gerekir.

2.4 Örnek Veri Seti

Aşağıdaki tablo, veri setindeki bir müşteri kaydının model açısından nasıl temsil edilebileceğini göstermektedir. Bu örnek kayıt, modelin hangi tür müşteri bilgilerini input olarak kullandığını daha anlaşılır hale getirmek amacıyla verilmiştir.

Bu örnekte görüldüğü gibi müşteri yalnızca kredi tutarı ile temsil edilmemektedir. Kredi süresi, kredi geçmişi, tasarruf seviyesi, çalışma süresi, taksit yükü, yaş, konut durumu ve iş tipi gibi farklı değişkenler birlikte değerlendirilmektedir.

Tablo 7. Örnek Müşteri Kaydı

Feature	Örnek Değer	Açıklama
status	1	Mevcut hesap durumu
duration	24	Kredi süresi
credit_history	2	Kredi geçmişi
purpose	3	Kredi amacı
amount	3000	Kredi tutarı
savings	2	Tasarruf seviyesi
employment_duration	3	Çalışma süresi
installment_rate	4	Taksit yükü
age	35	Müşteri yaşı
housing	2	Konut durumu
job	3	İş tipi
foreign_worker	2	Yabancı çalışan durumu

Bu örnek kayıt üzerinden şu yoruma vardım: model, müşteriye sadece tek bir değer üzerinden değerlendirmemektedir. Kredi tutarı, kredi süresi, tasarruf seviyesi, taksit yükü, çalışma süresi ve kredi geçmişi gibi değişkenler birlikte değerlendirilmektedir. Bu nedenle AI/ML tabanlı yaklaşım, kredi skorlama probleminde daha kapsamlı bir değerlendirme yapabilmek için uygundur.

Genel olarak veri seti incelendiğinde, kredi riskinin çok değişkenli bir problem olduğu görülmektedir. Bu durum, modelin yalnızca tek bir finansal göstergeye göre değil, müşterinin genel finansal profiline göre karar vermesi gerektiğini göstermektedir.

3. Yöntem / Model

3.1 Kullanılan Modeller

Bu projede kredi skortlama problemi için birden fazla makine öğrenmesi modeli değerlendirilmiştir. Bunun nedeni, doğrudan tek bir modeli seçmek yerine farklı modellerin güçlü ve zayıf yönlerini karşılaştırarak daha bilinçli bir seçim yapmaktır.

Kredi skortlama problemi için model seçerken yalnızca tahmin başarısına değil, modelin yorumlanabilirliğine de dikkat edilmiştir. Çünkü finansal karar destek sistemlerinde modelin neden belirli bir karar verdiğini açıklayabilmek önemlidir. Bu nedenle hem basit ve yorumlanabilir modeller hem de daha güçlü sınıflandırma modelleri değerlendirilmiştir.

Tablo 8. Değerlendirilen Model Yaklaşımları

Model	Kullanım Amacı	Avantajı	Sınırlılığı
Logistic Regression	Temel sınıflandırma modeli	Hızlı, anlaşılır ve yorumlanabilir	Doğrusal ilişkilerde daha başarılıdır
Balanced Logistic Regression	Sınıf dengesizliğini dikkate alan model	Riskli sınıfı daha iyi yakalayabilir	Genel accuracy değeri bir miktar düşebilir
Decision Tree	Kural tabanlı karar yapısını görmek	Yorumlaması kolaydır	Overfitting riski vardır
Random Forest	Birden fazla karar ağacını birleştirmek	Daha kararlı ve güçlü tahmin verebilir	Yorumlanabilirliği daha düşüktür

Bu modeller arasında özellikle Logistic Regression ve Balanced Logistic Regression modelleri kredi skortlama problemi için önemli görülmüştür. Logistic Regression, finansal risk problemlerinde sık kullanılan, hızlı ve yorumlanabilir bir modeldir. Balanced Logistic Regression ise sınıf dengesizliği durumunda riskli sınıfın daha iyi yakalanmasına yardımcı olabilir.

Decision Tree modeli, kararların ağaç yapısı üzerinden açıklanabilmesi nedeniyle değerlidir. Ancak tek bir karar ağacı bazı durumlarda eğitim verisine fazla uyum sağlayabilir. Random Forest ise birden fazla karar ağacını birleştirerek daha kararlı sonuçlar üretebilir; fakat yorumlanabilirliği Logistic Regression kadar kolay değildir.

Bu aşamada şu sonuca vardım: kredi skortlama probleminde modelin sadece iyi tahmin yapması değil, aynı zamanda karar mantığının açıklanabilir olması da önemlidir. Bu nedenle model seçiminde hem performans hem de yorumlanabilirlik birlikte düşünülmelidir.

3.2 Model Seçimi Gerekçesi

Kredi skortlama probleminde model seçimi yapılırken yalnızca accuracy değerine bakmak yeterli değildir. Accuracy, tüm tahminler içindeki doğru tahmin oranını gösterir. Ancak kredi riski probleminde hata türleri aynı öneme sahip değildir.

Örneğin iyi müşteriyi riskli tahmin etmek müşteri kaybına ve fırsat kaybına neden olabilir. Buna karşılık riskli müşteriyi iyi müşteri olarak tahmin etmek, finansal kurum açısından kredi geri ödenmeme riski oluşturabilir. Bu nedenle kredi riski probleminde riskli müşterileri yakalama başarısı özellikle önemlidir.


Bu projede model seçimi yapılırken accuracy metriğinin yanında precision, recall, F1-score ve confusion matrix gibi metriklerin de dikkate alınması planlanmıştır. Özellikle bad credit recall

değeri, kötü kredi riskine sahip müşterilerin ne kadarının doğru yakalandığını gösterdiği için önemli görülmüştür.

Tablo 9. Model Değerlendirmesinde Kullanılan Metrikler

Metrik	Anlamı	Kredi Riski Açısından Yorumu
Accuracy	Tüm tahminler içinde doğru tahmin oranı	Genel başarıyı gösterir fakat tek başına yeterli değildir
Precision	Riskli tahmin edilenlerin ne kadarının gerçekten riskli olduğu	Yanlış alarm oranını değerlendirmek için önemlidir
Recall	Gerçek riskli müşterilerin ne kadarının yakalandığı	Kredi riski açısından kritik bir metriktir
F1-score	Precision ve recall dengesini gösterir	Dengesiz veri setlerinde faydalıdır
Confusion Matrix	Sınıflandırma hatalarını gösterir	Hangi sınıfta hata yapıldığını analiz etmeyi sağlar

Şekil 4. Ön Model Karşılaştırması: Accuracy ve Bad Credit Recall



Grafikte görüldüğü gibi Logistic Regression modeli accuracy açısından güçlü görünmektedir. Ancak Balanced Logistic Regression modeli bad credit recall değerinde daha yüksek sonuç vermiştir. Kredi riski probleminde riskli müşterileri yakalama başarısı kritik olduğu için Balanced Logistic Regression modeli final model adayı olarak daha anlamlı değerlendirilmiştir.

Bu metrikleri incelediğimde özellikle recall değerinin kredi riski probleminde çok önemli olduğunu gördüm. Çünkü model riskli müşterileri yakalayamazsa, sistem finansal açıdan hatalı

kararlar üretebilir. Bu nedenle model seçiminde yalnızca genel başarı oranına değil, kötü kredi sınıfını yakalama başarısına da odaklanılmıştır.

Bu noktada Balanced Logistic Regression modeli final model adayı olarak öne çıkmaktadır. Standart Logistic Regression modeli bazı durumlarda daha yüksek genel accuracy verebilir; fakat kötü kredi sınıfını yakalama başarısı düşükse kredi riski açısından yeterli olmayabilir. Balanced Logistic Regression ise sınıflar arasındaki dengesizliği dikkate alarak riskli müşterileri daha iyi yakalamayı hedefler.

Model Seçimi Yorumu

Bu projede en yüksek accuracy değerini veren modelin otomatik olarak en iyi model kabul edilmemesi gerektiği sonucuna vardım. Kredi riski bağlamında önemli olan, finansal açıdan kritik hataları azaltmak ve riskli müşterileri daha başarılı yakalayabilmektir. Bu nedenle Balanced Logistic Regression modeli, kötü kredi sınıfını daha iyi yakalama potansiyeli nedeniyle güçlü bir final model adayı olarak değerlendirilmiştir.

3.3 Beklenen Model Çıktıları

Geliştirilecek modelin yalnızca sınıf tahmini üretmesi yeterli görülmemiştir. Çünkü kullanıcı veya finansal karar verici için yalnızca 0 veya 1 şeklinde bir çıktı yeterince açıklayıcı değildir. Bu nedenle model çıktısının daha anlaşılır ve karar sürecine uygun hale getirilmesi planlanmıştır.

Bu projede model çıktısı; kötü kredi olasılığı, iyi kredi olasılığı, kredi skoru, risk bandı ve karar önerisi şeklinde yorumlanacaktır. Böylece sistem yalnızca teknik bir tahmin modeli olarak değil, kredi başvurularını değerlendirmeye yardımcı olan bir karar destek sistemi olarak tasarlanmış olacaktır.

Tablo 10. Beklenen Model Çıktıları

Model Çıktısı	Açıklama
Prediction	Modelin sınıf tahmini
Prediction Label	İyi kredi veya kötü kredi yorumu
Bad Credit Probability	Müşterinin kötü kredi riski olasılığı
Good Credit Probability	Müşterinin iyi kredi olasılığı
Credit Score	300–850 aralığında model tabanlı kredi skoru
Decision	APPROVE / REVIEW / DECLINE
Risk Band	Low Risk / Medium Risk / High Risk

Bu çıktı yapısını özellikle seçtim çünkü kredi skorlama sistemleri yalnızca teknik model çıktısı üretmemelidir. Kullanıcı, müşteri veya finansal karar verici sistem sonucunu kolayca anlayabilmelidir. Bu nedenle modelin ürettiği olasılık değeri, daha anlaşılır olması için kredi skoru ve karar önerisi şeklinde yorumlanacaktır.

Temel mantık şu şekildedir: kötü kredi olasılığı arttıkça kredi skoru düşer; kötü kredi olasılığı azaldıkça kredi skoru yükselir. Buna göre düşük riskli başvurular için APPROVE, orta riskli başvurular için REVIEW, yüksek riskli başvurular için DECLINE karar önerisi üretilecektir.

Ara Rapor Genel Değerlendirmesi

Bu ara rapor aşamasında proje için seçilen problem, kullanılan veri seti ve modelleme yaklaşımı açıklanmıştır. Kredi skortlama probleminin finansal risk açısından önemli olduğu, bu nedenle model seçiminin yalnızca genel doğruluk oranına göre yapılamayacağı değerlendirilmiştir.

Veri seti incelendiğinde müşterinin kredi riskini etkileyebilecek birçok farklı değişken olduğu görülmüştür. Bu nedenle problem tek bir değişkene bağlı basit bir karar problemi olarak değil, çok değişkenli bir sınıflandırma problemi olarak ele alınmıştır. Kredi geçmişi, kredi tutarı, kredi süresi, tasarruf seviyesi, çalışma süresi ve taksit yükü gibi değişkenlerin birlikte değerlendirilmesi gerektiği sonucuna varılmıştır.

Modelleme yaklaşımında Logistic Regression, Balanced Logistic Regression, Decision Tree ve Random Forest gibi modellerin değerlendirilebileceği belirtilmiştir. Bu modeller arasında özellikle Balanced Logistic Regression modeli, kötü kredi sınıfını daha iyi yakalama potansiyeli nedeniyle önemli görülmüştür.

Bu ara rapor sonucunda vardığım temel çıkarım şudur: kredi skortlama problemlerinde başarılı bir AI/ML sistemi geliştirmek için yalnızca yüksek accuracy elde etmek yeterli değildir. Modelin riskli müşterileri yakalama başarısı, kararların finansal etkisi ve model çıktısının kullanıcı tarafından anlaşılabilir olması birlikte değerlendirilmelidir.

Final rapor aşamasında bu ara raporda açıklanan problem, veri seti ve modelleme yaklaşımı üzerine geliştirilen çalışan sistem detaylandırılacaktır. Bu kapsamda Streamlit arayüzü, FastAPI backend yapısı, sistem mimarisi, model performans sonuçları ve nihai değerlendirme bölümleri ayrıca sunulacaktır.